

人工智能Agent开发学习笔记

1. Function Call原理

Function Call是大模型的底层能力，大模型输出JSON格式工具调用指令，交给后端执行函数，Agent是基于Function Call构建的上层系统，可以完成多轮自主工具调用、思考决策。

2. RAG检索增强生成

RAG用来解决大模型幻觉、知识库更新问题。

流程：文档加载 → 文本切片chunk → embedding向量化 → 存入向量数据库；用户提问向量

3. 向量数据库FAISS

FAISS是轻量级本地向量库，适合做Demo测试，不需要额外部署服务。

企业生产环境一般使用Milvus。

4. Reranker重排序

向量检索召回多条文档，reranker做二次打分，过滤无关片段，提升RAG回答质量。

5. 大模型微调

LoRA属于参数高效微调，冻结大模型主干权重，只训练低秩矩阵，显存消耗小，适合指令微调。